

Avrupa Elektrik Yükü Tahminleme Projesi

Veri Bilimi ve Modelleme Çalışmaları Raporu

Tarih: 14 Mayıs 2026

Amaç: Avrupa ülkelerinin saatlik elektrik tüketim verilerini kullanarak yüksek doğruluklu makine öğrenimi tahminleme modelleri oluşturmak.

1. Algoritma Seçimi: Neden LightGBM?

Projenin ana modelleme algoritması olarak **LightGBM (Light Gradient Boosting Machine)** seçilmiştir. Bu tercihin ardındaki temel bilimsel ve teknik nedenler şunlardır:

- Zaman Serisi Performansı:** Elektrik tüketimi gibi mevsimsel, döngüsel ve gecikmeli (lag, rolling mean) özelliklerin (features) yoğun olduğu veri setlerinde ağaç tabanlı algoritmalar çok yüksek performans gösterir.
- Hız ve Verimlilik:** Elimizdeki saatlik elektrik tüketim verisi milyonlarca satırdan oluşmaktadır. LightGBM, XGBoost ve Random Forest gibi rakiplerine kıyasla bellek (RAM) dostu yapısı ve Histogram tabanlı ayırım mantığıyla devasa tabular verileri çok daha hızlı işler.
- GPU Hızlandırması:** `device='gpu'` parametresiyle CUDA çekirdekleri üzerinden paralel hesaplama yapılarak 37 ayrı modelin eğitim süresi dakikalara indirilmiştir.

2. Problem Tespiti ve Ölçek Uymazlığı (Scale Mismatch)

Projenin başlangıcında tüm ülkeler için tek bir Global (Genel) model eğitilmeye çalışıldı. Ancak Hollanda, Almanya ve Fransa gibi ülkelerin elektrik yükü 100.000 MW seviyelerindeyken, Arnavutluk gibi ülkelere bu rakamın 1.000 MW civarında olduğu gözlemlendi. Tek bir model, aralarındaki 100x ile 300x arasındaki bu uçurum nedeniyle düşük kapasiteli ülkelere çok yüksek hata payı üretiyordu.

Çözüm: 37 Bağımsız LightGBM Modeli Ölçek problemini ortadan kaldırmak için radikal bir kararla **her ülke için özel bir model** tasarlanmasına karar verildi. Hedef değişken olan `Value` sütununa, veri varyansını dengelemek amacıyla Logaritmik Dönüşüm (`np.log1p`) uygulandı ve çıktı alınırken ters dönüşüm (`np.expml`) yapıldı.

3. Veri Temizleme ve Aykırı Değer (Outlier) Operasyonları

Ülkelerin verileri istatistiksel olarak analiz edildiğinde çeşitli veri giriş (typo) hataları ve birim kaymaları saptandı.

Birim Hataları (Scaling Issues): Almanya (DE), Belçika (BE), Macaristan (HU), Lüksemburg (LU) ve Hollanda (NL) verilerinde, dağılımın tam olarak %50'sinin yanlışlıkla 10 ile çarpıldığı tespit edildi.

- Çözüm:** Her ülke için mantıklı bir üst eşik değeri belirlenerek (örn. $DE > 200,000$ MW), bu değeri aşan tüm satırlar **10'a bölündü** ve gerçek değerlerine getirildi.

Yazım Hataları (Typos): Bosna Hersek (BA) ve Romanya (RO) ülkelerinde, verilerin küçük bir kısmında 31 Trilyon MW gibi imkansız sayılar saptandı.

- **Çözüm:** İlgili anomali satırları tespit edilip silinmek (dropna) yerine, zaman serisi bütünlüğünü bozmamak adına **Outlier Imputation** yöntemi kullanıldı. Bozuk satırlar NaN yapıldıktan sonra, verinin ait olduğu ülkenin, o ayki ve o saatteki ortalama elektrik yükü hesaplanarak bu satırlara atandı.

4. Veri Yetersizliği: Kosova'nın (XK) Projeden Çıkarılması

Analizler sırasında Kosova'ya ait elektrik yükü verisinin oldukça sınırlı olduğu tespit edilmiştir.

- Kosova verisi sadece 2021 yılının Temmuz ayında başlamakta ve Aralık ayında bitmektedir (Sadece 6 aylık veri).
- Ağaç tabanlı zaman serisi modelleri daha önce eğitim verisinde görmedikleri mevsimsel şartları tahmin edemezler (Extrapolation problemi). Eğitim verisinde kış şartlarının ve dinamiklerinin hiç bulunmaması, modelin test verisinde (Aralık ayı) büyük oranlarda yanılmasına sebep olmuştur. Modellerin genel güvenilirliğini sarsmamak adına Kosova verisi eğitim öncesinde veri setinden **tamamen çıkarılmıştır**.

5. Dinamik Kronolojik Veri Bölme (Data Splitting)

Eski sistemde eğitim ve test verisi katı yıllara (2019, 2021, 2022 vb.) ayrılmıştı. Ancak İsveç, İngiltere gibi 23 ülkenin verisinin sadece 2021 yılına kadar olduğu keşfedildi.

- **Çözüm:** Veriler katı yıllara göre değil, zamansal sıraya (DateUTC) göre dizilerek **Dinamik Yüzdelik Oranlarla** bölündü.
- **Train:** İlk %70 | **Validation:** Sonraki %15 | **Test:** Son %15
Bu sayede her ülkenin veri uzunluğu ne olursa olsun kronolojik bütünlük korunarak doğru bir şekilde eğitim ve test yapılabilirdi.

6. Modellerin Dışa Aktarımı (Serialization)

37 modelin her çalıştırıldığında saatlerce eğitilmesinin önüne geçmek için tüm modeller `joblib` kütüphanesi kullanılarak `.pkl` formatında `output/models/` klasörüne aktarıldı. Yükleme işlemi modüler bir yaklaşımla `5_load_models.ipynb` isimli ayrı bir dosyaya taşındı.

Sonuç

Bu optimizasyonlar sonucunda veri anormallikleri ve ölçek uyumsuzlukları giderilmiş, Avrupa ülkeleri için yüksek doğruluk oranlarına sahip, Dashboard entegrasyonuna hazır tam 37 adet özelleştirilmiş LightGBM makine öğrenimi modeli başarıyla elde edilmiştir.